Asistente de Inteligencia Artificial para la Planificación Docente

Proyecto final · Aprendizaje Automático (IAE-2501)
Autora: Jhessika Lidabed Espaillat Espaillat
Docente: Feibert Guzmán
Fecha: noviembre de 2026

Resumen

Se diseñó y ejecutó un prototipo académico de clasificación supervisada para sugerir estrategias pedagógicas y producir borradores de planificación. Se trabajó con 480 escenarios sintéticos y se compararon regresión logística y Random Forest. Los resultados cuantifican el comportamiento sobre etiquetas creadas artificialmente: no constituyen validación pedagógica real.

1. Problema y justificación

La planificación docente requiere organizar competencias, contenidos, actividades y evaluación según el contexto del aula. La selección de estrategias para grupos diversos puede demandar tiempo. El prototipo explora un flujo reproducible de datos y Machine Learning que apoye al docente sin sustituirlo.

2. Objetivo general

Construir y evaluar técnicamente, sobre datos sintéticos, un prototipo experimental que clasifique estrategias pedagógicas en escenarios docentes y genere un borrador estructurado para revisión humana.

3. Objetivos específicos

1) Construir un dataset sintético con variables pedagógicas. 2) Realizar análisis exploratorio y preprocesamiento. 3) Comparar regresión logística y Random Forest con validación cruzada. 4) Analizar métricas y limitaciones. 5) Desplegar una aplicación de demostración y documentar el proceso.

4. Pregunta de investigación

¿Cómo puede un clasificador supervisado integrarse en un prototipo de planificación docente y qué desempeño técnico alcanza al aprender etiquetas artificiales basadas en reglas?

5. Datos y variables

Unidad: escenario sintético de solicitud docente. N=480 registros artificiales, identificador SIN-0001 a SIN-0480. Entradas: nivel, asignatura, necesidad, tipo de contenido, recursos, duración. Variable dependiente: estrategia. Etiquetado determinista: Refuerzo→Práctica guiada; Colaboración→Aprendizaje cooperativo; Aplicación→Aprendizaje basado en problemas; Profundización→Proyecto de profundización. No se recolectaron datos personales ni se pidió a expertos etiquetar.

6. Metodología y ETL

Extraer: se generaron ejemplos programáticamente con combinaciones de categorías. Transformar: se inspeccionaron faltantes, duplicados, distribuciones de clases y se codificaron variables categóricas mediante OneHotEncoder. Cargar: CSV codificado en UTF-8. Se separó 75% entrenamiento (360 registros) y 25% prueba (120 registros), estratificando por clase; se aplicó validación cruzada de cinco particiones solo en entrenamiento.

7. Modelos

Se comparó regresión logística multinomial implementada mediante LogisticRegression con RandomForestClassifier de 120 árboles y min_samples_leaf=2. Se utilizó Pipeline para unir preprocesamiento y clasificador, evitando ajustar transformaciones con el conjunto de prueba. El modelo se eligió por F1 macro promedio de validación cruzada; en el empate, se seleccionó Random Forest según el orden del procedimiento de comparación.

8. Resultados reproducibles

En esta ejecución, ambos modelos obtuvieron F1 macro de validación cruzada = 1.00; exactitud (accuracy) de prueba = 1.00; precisión macro = 1.00; recall macro = 1.00; y F1 macro de prueba = 1.00. Se evaluó un conjunto de 120 registros. Estos resultados perfectos se explican por la relación determinista entre la entrada «necesidad» y la etiqueta de salida; NO prueban que la estrategia sea apropiada en contextos educativos reales.

9. Prototipo web y resultados de uso

La aplicación Streamlit carga el clasificador entrenado, permite seleccionar entradas, muestra una estrategia y construye mediante reglas un borrador con inicio, desarrollo, cierre y evaluación. El borrador NO lo produce un LLM: la IA generativa queda como posible fase futura. La publicación pública en Streamlit debe completarla la estudiante desde su cuenta.

10. Riesgos, limitaciones y ética

La validez externa es nula en esta fase porque las etiquetas son sintéticas y no hay evaluación con expertos ni docentes. Existe riesgo de sesgo, recomendaciones improcedentes, sobreajuste a reglas y falsa confianza en métricas perfectas. Mitigaciones: avisos claros, revisión humana, no introducir datos identificables, nueva validación con datos autorizados y análisis por subgrupos.

11. Conclusión y siguientes pasos

Se demostró la factibilidad técnica de una canalización sencilla de Machine Learning integrada a una aplicación web. Para sostener beneficios en calidad y tiempo de planificación será necesario diseñar una rúbrica con docentes, recolectar casos autorizados, evaluar concordancia entre evaluadores, medir satisfacción y pertinencia, y probar el sistema con escenarios educativos reales.

12. Referencias

Guzmán Pérez, F. A. (2026). Proyecto: Machine Learning [Plantilla académica de clase].
Cruz Evangelista, A. (2026). Bitácora pedagógica de clase: Inteligencia artificial [Material de curso].
Scikit-learn developers. (s. f.). Scikit-learn documentation. https://scikit-learn.org/stable/
Streamlit. (s. f.). Documentation. https://docs.streamlit.io/
GitHub. (s. f.). GitHub Docs. https://docs.github.com/

Anexo: resumen comparativo de métricas

Modelo	F1 validación cruzada	F1 prueba
Random Forest	1.00	1.00
Regresión logística	1.00	1.00

Nota: mediciones sobre datos sintéticos etiquetados por reglas; desempeño real no demostrado.